

TP3 Statistiques : Estimation du maximum de vraisemblance et l'intervalle de confiance

21 mars 2025

Le modèle d'un paramètre: La loi Bernoulli

Soit X_1, \dots, X_n un échantillon de Bernoulli $\mathcal{B}(p)$ avec $p = 0.6$. Nous voulons estimer p à partir d'une réalisation de cet échantillon $x = (x_1, \dots, x_n)$. de X

Ex1. Simuler un échantillon i.i.d de taille $n = 10$ en utilisant `rbinom`.

```
n <- ...
p <- ...
x <- rbinom(n=...,size = ..., prob =... )
```

Quelle est une estimation simple de p ?

Ex2. Créer une fonction de vraisemblance, nommée `L_bern`, en fonction de (p, x) , qui donne la vraisemblance d'un échantillon $x = (x_1, \dots, x_n)$ pour une valeur donnée de p .

```
L_bern <- function(p, x){## vraisemblance
  ...
  return(...)}
}
```

Ex3.. Pour l'échantillon généré dans l'**Ex1**, calculer la vraisemblance de cet échantillon des lois Bernoulli de paramètres p allant de 0 à 1. Tracer la courbe des valeurs calculées. Que remarquez-vous?

```
pvec = seq(0,1,by=...)
Lp = sapply(pvec, L_bern, x=...)
Lp
plot(pvec, Lp)
```

Ex4.. En utilisant la fonction `optim` de R, trouvez la valeur de p la plus probable d'avoir généré cet échantillon.

```
?optim ### la description de l'optim

mL_bern <- function(p,x){ -L_bern(p,x) }
## optimization standard (minimization)
p0 = ... # valeur initiale pour l'algorithme
res = optim(p0, mL_bern, x=x, method = "...")
res
```

Attention : `optim` est par défaut une routine de **minimization**. Avec la méthode de *L-BFGS-B* dans la fonction `optim`, vous pouvez traiter des contraintes sur le(s) paramètre(s), lorsque qu'il est nécessaire.

```
## optimization avec contraintes
pmin = ...; pmax = ...
res1 = optim(p0, mL_bern, x=x, method="L-BFGS-B", lower=pmin, upper=pmax)
res1
```

Ex5. Tester avec des échantillons de taille n allant de $n = 10$ à $n = 2000$ et comparer l'écart entre la valeur

```
size <- seq(10,2000, by=...)
para <- ...

for(k in ...)
{
  x<-rbinom(k,1,p)
  pmin<-...
  pmax<-...
  res2 <- optim(...)
  para[k]<-res2$par
}
```

```
log_L <- function(p,x){ ... } #log vraisemblance
size <- seq(10,2000, by=...)
...
for(k in size)
{
  ...
}
plot(...)
```

Alternativement, donner les intervalles de confiance d'après l'inégalité de Bienaymé-Chebycheff et l'inégalité de Hoeffding.

Un modèle à deux paramètres: La loi Beta

```
n<-...
theta<-c(...)
X <- rbeta(...)
head(X)
```

```
theta_0 <- theta
X<- rbeta(n=...,...)
theta_1 <- ...
theta_2 <- ...
xx<- seq(..., by=...)
hist(X,..., main = "...")
lines(xx,dbeta(...),col="red")
lines(xx,dbeta(...),col="blue")
legend("topright", legend=c("Beta(...)", "Beta(...)"),col = c("red", "blue"),lty = c(1,1))
```

Ex9. Générer une fonction de la log-vraisemblance avec les arguments (θ, x) , qui donne la log-vraisemblance d'un échantillon $x = (x_1, \dots, x_n)$ pour une valeur donnée de $\theta = (\alpha, \beta)$. Pour votre échantillon, évaluer la log-vraisemblance de paramètre $\theta = (\alpha, \beta)$, en faisant varier un paramètre à la fois, et visualiser la fonction sur $a_0 \leq \alpha \leq a_1, b_0 \leq \beta \leq b_1$ pour votre choix appropriés de limites. Que remarquez-vous?

Indication : Pour plus de simplicité, il suffit de tracer la tranche des courbes unidimensionnelle en supposant que l'autre est fixe: $\ell(\alpha|\beta = \beta_0)$ pour plusieurs valeurs de β_0 et $\ell(\beta|\alpha = \alpha_0)$ pour plusieurs valeurs de α_0 .

Nous pouvons également utiliser des visualisations 2-dim ou 3-dim avec `contour` ou `image`. Une visualisation plus avancée peut être réalisée à l'aide du module (`plot3D`). Voici un exemple de code.

```
aa = seq(0.5, 5, by=...)
bb = seq(0.5, 6, by=0.2)
vtheta = expand.grid(a=aa, b=bb); vtheta

# evaluer la (negative) vraisemblance
mlogL_beta = ...
log_lik = apply(vtheta, 1, mlogL_beta, x=X)
cbind(vtheta, log_lik)
# chercher le minimum
iopt = which.min(log_lik)
a1 = vtheta[iopt,1]
b1 = vtheta[iopt,2]
## transformer en matrice
zmat = matrix(log_lik, nrow=length(aa), ncol=length(bb))
rownames(zmat) = aa
colnames(zmat) = bb
## contour plots
?contour
contour(aa, bb, zmat)
points(a1, b1, pch=8, col=2) ## ajouter les points minimum
```

Ex10. Donner l'expression mathématique du vecteur Score (les dérivées premières) à laquelle l'EMV répond et trouver l'information de Fisher. En utilisant la fonction `optim`, trouver l'estimateur du maximum de vraisemblance. Quelle est la loi asymptotique d'estimateur?

Ex11. Construire des intervalles de confiance asymptotique de niveau 0.90. Incluent-ils les vrais paramètres ? Tester avec des échantillons de taille $n = 20$ et $n = 100$. Quel est l'effet de la taille de l'échantillon ?

Ex12. Répéter l'estimation 100 fois avec de nouveaux ensembles de données et tracer les valeurs estimées $\hat{\alpha}$ vs $\hat{\beta}$. Sont-elles indépendantes ? Visualisez vos résultats à l'aide d'un histogramme. Ajoutez la densité de la loi asymptotique. Que remarquez-vous?

Ex13. Réalisez une étude de simulation pour évaluer la performance des intervalles de confiance et résumez vos conclusions.